

بسم الله الرحمن الرحيم

تمرین‌های سری سوم درس داده‌کاوی – نیم‌سال اول ۱۴۰۴-۰۵

علی جمعه‌ئی – ۴۰۴۷۲۳۸۶۴

پاسخ پرسش یک

در پاسخ این پرسش به چند مورد زیر می‌توان اشاره کرد:

- انطباق مواردی که در تحلیل مهم هستند با ابعاد موجود، در این روش ابعاد داده‌ها هر کدام یکی از محورهایی است داده‌ها بر آن قرار گرفته‌اند، بنابراین
 - هم خود این پارامترهای تحلیل برای تحلیلگر است که موضوعیت دارد و در یک نگاه کلان می‌تواند همه‌ی اوضاع را ببیند
 - هم این که عملگرهایی نظیر Slice، Roll-up یا Drill-down است که با این شیوه‌ی نمایش تعریف‌های شفاف و متناسب با نیازمندی‌های تحلیلگر خواهد یافت.
- تجمیع (aggregation) و سایر بررسی‌های آماری در این مدل سریع‌تر و شهودی‌تر خواهد بود.
- از آن‌جا که وابستگی‌ها به شهود انسانی نزدیک‌تر است (نسبت به OLTP و فهم جدول SQL و ER از ماجرا) ارایه تحلیل برای تحلیل‌گرها ساده‌تر خواهد بود.

پاسخ پرسش دو

مطابق تعریف ویکی‌پدیا (Wikipedia, 2025) ¹FASMI واژه‌ی جایگزینی برای OLAP است که به دلیل جنجالی و جانبگیرانه بودن ۱۲ قانون OLAP پیش‌نهاد شده است. همین‌طور chatgpt می‌گوید می‌گوید قالب پنج‌تایی که نشان‌دهنده چقدر خوب عمل‌کردن یک سامانه پیاده‌سازی OLAP است را نشان می‌دهد. هر چند برای این تعریف نتوانستم منابع مورد نظر را پیدا کنم اما به نظر منطقی و درست بود.

- سریع، یعنی سامانه باید با سرعت قابل قبولی درخواست تحلیلگر را پاسخ دهد
- تحلیلی، سامانه باید قابلیت انجام عملیات‌های تحلیلی را داشته باشد
- اشتراکی، سامانه باید قابلیت استفاده از چندین پایگاه داده² و قابلیت پذیرش چندین تحلیلگر را داشته باشد

¹ Fast Analysis of Shared Multidimensional Information

² این بخش مربوط به چندین پایگاه داده در گفته‌ی chatgpt نبود و خودم حدس زدم که باید باشد

- چندبعدی
- اطلاعات،

پاسخ پرسش سه

مطابق وب‌نوشته IBM (Sinha, 2025) تفاوت اصلی OLAP و OLTP همان‌طور که در نام آن‌ها منعکس شده است، در تحلیلی و تراکنشی بودن این دو و بهینه‌سازی هر کدام از سامانه‌ها برای آن هدف است. OLAP برای دانشمندان داده و تحلیلگران تجاری بهینه شده در حالی که OLTP برای تعداد پرشمار تراکنش و سامانه‌هایی در خط حمله مانند بانک‌ها، خدمات تجاری اینترنتی و مانند آن طراحی شده است. همین‌طور موارد زیر تفاوت‌های کلیدی این دو مفهوم می‌باشد:

- تمرکز: OLAP اجازه استخراج داده برای تحلیل‌های پیچیده را می‌دهد. این تحلیل‌ها برای جهت‌دهی به تصمیم‌گیری‌های تجاری و مانند آن مورد استفاده است. درخواست‌ها و queryها گاهی شامل خطوط بزرگی از داده‌ها هستند. درحالی که OLTP برای به‌روزرسانی‌ها ساده، وارد کردن داده‌های جدید یا حذف آن‌ها در پایگاه داده مفید هستند.
- منبع داده: معمولاً منبع داده‌ی OLAP یک یا چند OLTP تجمیع شده است. در حالی که OLTP از یک DBMS استفاده می‌کند.
- زمان پردازش: در OLAP زمان واکنش چند مرتبه از OLTP کندتر است.
- در دسترس‌بودگی³: در دسترس‌بودگی برای OLTP یک وضعیت حیاتی است اما در OLAP به‌روزرسانی و آماده بودن خیلی موضوعیت ندارد.

در نهایت می‌توان گفت اگر به یک سامانه‌ای نیاز است که تراکنش‌های روزانه را مدیریت می‌کند OLTP گزینه‌ی مناسبی است اما اگر به یک ابزاری نیاز است که بینش تجاری بدهد، OLAP مناسب است.

پاسخ پرسش چهار

بعد یکی از شاخصه‌های تجاری نظیر دسته‌بندی، وزن محصول، قیمت محصول یا نظایر آن است. این شاخصه‌ها به یک یا چند ستون در یک یا چند جدول در نمای منبع داده (Data Source View) نمایش داده می‌شوند.

پاسخ پرسش پنج

مطابق تعریف IBM (2021, IBM)، یک جدول واقعیت (Fact Table) یا موجودیت واقعیت (Fact Entity)، جدولی یا موجودیتی در یک طرح ستاره‌ای (Star Schema) یا طرح دانه‌برفی (Snowflake Schema) است که اندازه‌گیری‌هایی (Measures) را ذخیره می‌کند که عملکرد کسب‌وکار را اندازه‌گیری می‌کنند، مانند فروش، بهای تمام‌شده کالا، یا سود.

جداول و موجودیت‌های واقعیت، اندازه‌گیری‌ها یا همان داده‌های عددی مربوط به کسب‌وکار را تجمیع (Aggregate) می‌کنند. برای اندازه‌گیری داده‌ها در یک جدول یا موجودیت واقعیت، تمام اندازه‌گیری‌های موجود در آن جدول یا موجودیت باید دارای دانه‌بندی (Grain) یکسان باشند.

برای به‌دست‌آوردن داده‌های مفیدتر در یک جدول یا موجودیت واقعیت، باید از اندازه‌گیری‌هایی استفاده کنید که هم عددی و هم جمع‌پذیر (Additive) باشند. استفاده از این نوع اندازه‌گیری‌ها تضمین می‌کند که داده‌ها بتوانند بازیابی و تجمیع شوند تا کسب‌وکار بتواند از حجم عظیم داده‌های موجود در پایگاه داده استفاده کند.

جداول و موجودیت‌های واقعیت همچنین شامل کلیدهای خارجی (Foreign Keys) به جداول ابعاد (Dimension Tables) هستند. این کلیدهای خارجی، هر ردیف داده در جدول واقعیت را به ابعاد و سطوح (Levels) متناظر آن مرتبط می‌سازند.

جداول و موجودیت‌های واقعیت از کلیدهای اصلی مرکب (Composite Primary Keys) استفاده می‌کنند. یک کلید مرکب از زیرمجموعه‌ای از کلیدهای دیگر تشکیل شده است. اگر یک جدول یا موجودیت در مدل داده‌ای بُعدی (Dimensional Model) از یک کلید مرکب استفاده کند، در آن صورت آن جدول یا موجودیت یک جدول یا موجودیت واقعیت است. استفاده از کلیدهای مرکب باعث می‌شود که جدول یا موجودیت، رابطه‌ای چندبه‌چند (Many-to-Many) با سایر جداول و موجودیت‌ها در مدل داده‌ای بُعدی داشته باشد.

پاسخ پرسش شش

در مدل‌های داده‌ای چندبعدی، Event Facts و Snapshot Facts دو نوع جدول واقعیت هستند که تفاوت اصلی آن‌ها در ماهیت و زمان‌بندی داده‌هاست. Event Facts داده‌هایی را ذخیره می‌کنند که مربوط به رخداد‌های منفرد و مشخص کسب‌وکار هستند، مانند یک سفارش فروش یا یک تراکنش بانکی؛ این نوع Facts برای تحلیل‌هایی مناسب است که نیاز به بررسی جزئیات تراکنش‌ها و رویدادها به تفکیک زمان دقیق دارند. در مقابل، Snapshot Facts داده‌هایی را ثبت می‌کنند که نمایانگر وضعیت سیستم در

یک بازه زمانی مشخص هستند، مانند موجودی کالا در پایان روز یا مانده حساب ماهانه؛ این نوع Facts برای تحلیل‌هایی کاربرد دارد که هدف آن‌ها بررسی روندها، تغییرات و وضعیت کلی در طول زمان است. به عبارت دیگر، Event Facts برای تحلیل‌های تراکشی و لحظه‌ای و Snapshot Facts برای تحلیل‌های دوره‌ای و روندی استفاده می‌شوند.

پاسخ پرسش هفت

براساس توضیح موجود در تارنمای IBM (2020, IBM) سه نوع Measure عبارت است از:

جمع‌پذیر: Measures، اندازه‌گیری‌هایی هستند که می‌توان آن‌ها را در تمام ابعاد جدول واقعیت (Fact Table) تجمیع کرد و متداول‌ترین نوع Measure هستند. این نوع Measures معمولاً در چندین بعد برای محاسبه مجموع استفاده می‌شوند.

چون مدل‌سازی چندبُعدی شامل سلسله‌مراتب‌ها در ابعاد است، تجمیع اطلاعات در سطوح مختلف سلسله‌مراتب یک عنصر کلیدی در مفید بودن مدل است. از آنجایی که تجمیع یک فرآیند جمع‌پذیر است، بهتر است تا حد امکان از Measures جمع‌پذیر استفاده شود.

نیمه‌جمع‌پذیر: Measures نیمه‌جمع‌پذیر می‌توانند در برخی ابعاد تجمیع شوند، اما نه در همه ابعاد. برای مثال، Measures مانند تعداد پرسنل و موجودی کالا جزو نیمه‌جمع‌پذیر محسوب می‌شوند

غیرجمع‌پذیر: Measures غیرجمع‌پذیر، اندازه‌گیری‌هایی هستند که در هیچ یک از ابعاد نمی‌توان آن‌ها را تجمیع کرد. این Measures به‌طور منطقی بین ردیف‌ها یا رکوردهای جدول واقعیت قابل جمع‌بندی نیستند. معمولاً Measures غیرجمع‌پذیر نتیجه نسبت‌ها یا محاسبات ریاضی دیگر هستند. تنها محاسبه‌ای که می‌توان روی چنین Measure‌هایی انجام داد، شمارش تعداد ردیف‌ها است.

پاسخ پرسش هشت

در مورد تفاوت Data warehouse و Operational Database می‌توان گفت؛ به ترتیب برای OLAP و OLTP طراحی و بهینه شده است، همین‌طور همه ویژگی‌های عملیاتی مطرح شده پاسخ پرسش سه نیز معمولاً در آن‌ها لحاظ شده است.

پاسخ پرسش نه

در عبارت ETL اولین حرف به معنی استخراج داده از منابع متفاوت است، T که به انتقال داده‌ها اشاره دارد دقیقاً مربوط به همین حفظ یک‌پارچگی است. در این مرحله داده‌ها یک‌پارچه و تمیز می‌شوند و سپس در مرحله L یا بارگذاری در warehouse قرار خواهند گرفت.

پاسخ پرسش ده

زمان در تحلیل‌های مبتنی بر داده نقش مهمی دارد. فرض کنیم یک فروشگاه محصولی مانند یک لباس را می‌فروشد. قیمت لباس در پایگاه داده‌ی عملیاتی تنها به روزرسانی می‌شود و تاریخ این به‌روزرسانی‌ها جایی درج نمی‌شود اما دقیقاً همین تاریخ به‌روزرسانی و قیمت‌های جدید است که در data warehouse ذخیره می‌شود تا تحلیلگر امکان تحلیل داشته باشد.

پاسخ پرسش یازده

ویژگی Non-Volatile در Data Warehouse به این معناست که داده‌ها پس از بارگذاری تغییر نمی‌کنند یا به ندرت تغییر می‌کنند؛ یعنی رکوردهای ذخیره‌شده پایدار هستند و عملیات حذف یا به‌روزرسانی روزمره روی آن‌ها انجام نمی‌شود. این ویژگی تأثیر مهمی بر طراحی ساختار داده و نوع Query‌های تحلیلی دارد:

- طراحی ساختار داده: از آنجایی که داده‌ها تغییر نمی‌کنند، می‌توان از جدول‌های بزرگ و تجمیعی (Aggregated Tables) و ساختارهای Denormalized مانند Star Schema یا Snowflake Schema استفاده کرد تا دسترسی سریع به داده‌ها برای تحلیل‌ها ممکن شود. نیازی به پیچیدگی و کنترل تغییرات داده‌ها مانند سیستم‌های عملیاتی نیست.
- نوع Query‌های تحلیلی: Queries در محیط Non-Volatile معمولاً تحلیلی و خواندنی (Read-Only) هستند و شامل جمع، میانگین، روند، مقایسه بین دوره‌ها و Drill-Down/Drill-Up می‌شوند. چون داده‌ها ثابت هستند، بهینه‌سازی برای خواندن سریع و تحلیل بزرگ داده‌ها اهمیت دارد.
- عدم نیاز به Normalization: در Data Warehouse به دلیل Non-Volatile بودن، نیاز به Normalization شدید که در OLTP برای جلوگیری از افزونگی و به‌روزرسانی‌های مکرر ضروری است، وجود ندارد. می‌توان داده‌ها را Denormalize کرد تا سرعت Query‌های تحلیلی افزایش یابد، بدون نگرانی از مشکلات به‌روزرسانی یا ناسازگاری داده‌ها.

به‌طور خلاصه، Non-Volatile بودن داده‌ها اجازه می‌دهد ساختارهای تحلیلی ساده، سریع و بهینه برای خواندن طراحی شود و نیازی به پیچیدگی‌های OLTP مثل Normalization نیست.

پاسخ پرسش دوازده

در طراحی معماری Data Warehouse سه رویکرد اصلی وجود دارد: Top-Down (Inmon)، Bottom-Up (Kimball) و Hybrid. در رویکرد Top-Down، ابتدا یک Enterprise Data Warehouse

یکپارچه طراحی و پیاده‌سازی می‌شود و سپس Data Marts جداگانه برای بخش‌های مختلف کسب‌وکار ایجاد می‌شوند؛ مزیت آن یکپارچگی کامل داده‌ها و استانداردسازی است، اما هزینه و زمان پیاده‌سازی بالا و پیچیدگی زیادی دارد. در رویکرد Bottom-Up، ابتدا Data Marts موضوعی و محدود برای واحدهای خاص کسب‌وکار ساخته می‌شوند و در ادامه با ترکیب آن‌ها یک Data Warehouse جامع شکل می‌گیرد؛ این روش سریع‌تر و کم‌هزینه‌تر است ولی ممکن است مشکلاتی در یکپارچگی و استانداردسازی داده‌ها ایجاد شود. رویکرد Hybrid ترکیبی از دو روش فوق است، به‌گونه‌ای که هم Data Warehouse مرکزی و هم Data Marts موضوعی به موازات هم توسعه می‌یابند؛ مزیت آن انعطاف‌پذیری و تعادل بین یکپارچگی و سرعت پیاده‌سازی است، اما طراحی و نگهداری آن پیچیده‌تر است و نیاز به هماهنگی دقیق بین تیم‌ها دارد.

پاسخ پرسش سیزده

الف- event fact چرا که هر «بازدید» یک رویداد (event) است که در یک زمان مشخص اتفاق می‌افتد و داده در سطح تراکنش ذخیره می‌شود.

ب- event fact چون هر «خرید» نیز یک رویداد تراکنشی است که در زمان مشخصی رخ می‌دهد و اطلاعات آن لحظه ذخیره می‌شود.

پ- State Fact (Snapshot Fact) برای این که داده نمایانگر وضعیت سیستم در یک زمان خاص است (مصرف CPU در پایان روز) نه یک رویداد خاص.

ارجاع‌ها

IBM. (2020, 2 8). *Measures*. Retrieved from IBM:

<https://www.ibm.com/docs/en/ida/9.1.2?topic=models-measures>

IBM. (2021, 03 08). *Fact tables and entities*. Retrieved from IBM:

<https://www.ibm.com/docs/en/ida/9.1.2?topic=models-fact-tables-entities>

Sinha, T. (2025, 11 7). *OLAP vs. OLTP: What's the difference?* Retrieved from IBM:

<https://www.ibm.com/think/topics/olap-vs-oltp>

Wikipedia. (2025, 11 07). *FASMI*. Retrieved from Wikipedia:

<https://en.wikipedia.org/wiki/FASMI>