

درباره تفاوت Hadoop و Spark

مقدمه

مطابق توضیح‌های ارائه شده در تارنمای¹ می‌توان گفت:

پروژه Apache Hadoop نرم‌افزارهای متن‌باز را برای رایانش توزیع‌شده قابل اعتماد و مقیاس‌پذیر توسعه می‌دهد.

کتابخانه نرم‌افزاری Apache Hadoop یک چارچوب است که امکان پردازش توزیع‌شده مجموعه داده‌های بزرگ را در میان کلاسترهایی از رایانه‌ها با استفاده از مدل‌های برنامه‌نویسی ساده فراهم می‌کند. این چارچوب طوری طراحی شده است که از یک سرور تکی تا هزاران ماشین – که هرکدام محاسبات و ذخیره‌سازی محلی ارائه می‌دهند – مقیاس‌پذیر باشد. به جای تکیه بر سخت‌افزار برای ارائه دسترس‌پذیری بالا، خود این کتابخانه طوری طراحی شده است که خطاها را در لایه کاربرد شناسایی و مدیریت کند؛ در نتیجه می‌توان بر روی یک کلاستر از رایانه‌ها – که هر یک ممکن است مستعد خرابی باشند – یک سرویس با دسترس‌پذیری بالا ایجاد کرد. گفتنی است پروژه Hadoop شامل ماژول‌های زیر است:

Hadoop Common: ابزارها و کتابخانه‌های مشترکی که از دیگر ماژول‌های Hadoop پشتیبانی می‌کنند.

Hadoop Distributed File System (HDFS™): یک سامانه فایل توزیع‌شده که دسترسی با توان‌گذر بالا به داده‌های کاربردی را فراهم می‌کند.

Hadoop YARN: ایده بنیادی YARN این است که وظایف مدیریت منابع و زمان‌بندی/نظارت بر کارها را به daemon جداگانه تقسیم کند. این معماری شامل یک ResourceManager سراسری و یک ApplicationMaster برای هر برنامه است. برنامه می‌تواند یک کار (Job) واحد یا یک گراف جهت‌دار بدون چرخه (DAG) از کارها باشد².

Hadoop MapReduce: سامانه‌ای مبتنی بر YARN برای پردازش موازی مجموعه داده‌های بزرگ.

¹ <https://hadoop.apache.org/>

² <https://hadoop.apache.org/docs/current/hadoop-yarn/hadoop-yarn-site/YARN.html>

Spark چه ارتباطی با Apache Hadoop دارد؟

مطابق بخش سوالات پرتکرار در تارنمای ³Spark:

Spark یک موتور پردازشی سریع و همه‌منظوره است که با داده‌های هادوپ سازگار است.

این موتور می‌تواند در کلاسترهای Hadoop از طریق YARN یا در حالت مستقل (Standalone) اجرا شود و قادر است داده‌های موجود در HDFS، HBase، Cassandra، Hive و Hadoop InputFormat را پردازش کند.

Spark طوری طراحی شده است که هم پردازش دسته‌ای (Batch Processing) مشابه MapReduce و هم بارهای کاری جدید مانند پردازش جریانی (Streaming)، کوئری‌های تعاملی و یادگیری ماشین را انجام دهد.

³ <https://spark.apache.org/faq.html>